

Radyomik Özellikler Kullanılarak Papilödem Sınıflandırması

Veri Sızıntısız İleri Makine Öğrenmesi Pipeline'ı
Yapay Zeka Dersi — Final Ödevi (Seçenek A)

Üniversite	Üsküdar Üniversitesi
Program	Yapay Zeka Mühendisliği — Tezsiz Yüksek Lisans
Öğrenci	Muhammed Yıldırım SÜRMEN
Öğrenci No	254329041

Özet

Bu çalışmada, 746 radyomik özellik içeren bir veri seti üzerinde Normal ve Papilödem sınıflarını ayıran, veri sızıntısını (data leakage) önleyen uçtan uca bir makine öğrenmesi pipeline'ı geliştirilmiştir. Hasta seviyesinde veri bölme, eğitim verisinde fit edilen ön işleme, MRMR özellik seçimi, Optuna ile hiperparametre optimizasyonu (TPE, 50 deneme), altı taban model, olasılık kalibrasyonu ve soft-voting ensemble uygulanmış; sonuçlar istatistiksel testlerle değerlendirilmiştir.

Toplam 966 örnek | 69 hasta | 746 ham özellik | 50 Optuna denemesi

1. Giriş

Papilödem, optik diskin kafa içi basınç artışına bağlı ödemidir ve erken tanısı klinik açıdan kritiktir. Radyomik (radiomics) yaklaşımı, görüntülerden çok sayıda sayısal özellik çıkararak hastalık ayırımı otomatikleştirmeyi amaçlar. Bu çalışmanın amacı, yüksek boyutlu radyomik özelliklerden hareketle bir örneğin Normal veya Papilödem sınıfına ait olup olmadığını tahmin eden ikili bir sınıflandırma sistemi geliştirmektir. Çalışmanın temel ilkesi, gerçek akademik çalışmalarda olduğu gibi veri sızıntısını önleyen bilimsel bir metodolojidir: tüm ön işleme yalnızca eğitim verisinde öğrenilmiş, aynı hastaya ait görüntüler asla farklı kümelerle dağıtılmamıştır.

2. Veri Seti

Çalışmada iki radyomik veri seti kullanılmıştır: `normal_radiomics.csv` ve `papilodem_radiomics.csv`. Her örnek için 746 radyomik özellik (`Feature_0001 ... Feature_0746`) bulunmaktadır. Veri yapısı şu şekildedir:

Özellik	Değer
Toplam örnek (görüntü)	966
Benzersiz hasta	69
Hasta başına görüntü	14
Normal / Papilödem (örnek)	672 / 294
Ham özellik sayısı	746
Sınıf etiketi	Normal = 0, Papilödem = 1

Tablo 1. Veri seti özeti.

Önemli bir gözlem: **PatientIndex** sütunu her iki dosyada da 1'den başlayarak tekrar ettiğinden, hasta kimlikleri sınıf ön ekiyle (N_, P_) benzersizleştirilmiş ve grup-bazlı bölmede bu kimlikler kullanılmıştır.

3. Metodoloji

Geliştirilen pipeline, ödev akış şemasına (Ek Şekil 1) uygun olarak aşağıdaki sırayı izler: (1) veri birleştirme ve etiketleme, (2) hasta seviyesinde eğitim/test bölme, (3) ön işleme, (4) MRMR özellik seçimi, (5) Optuna ile hiperparametre optimizasyonu, (6) model eğitimi ve kalibrasyon, (7) soft-voting ensemble, (8) test değerlendirilmesi, (9) istatistiksel karşılaştırmalar ve görselleştirme.

3.1 Hasta Seviyesinde Bölme

Veri, **GroupShuffleSplit** ile %80 eğitim / %20 test olacak şekilde **hasta bazında** bölünmüştür. Böylece bir hastanın 14 görüntüsünün tamamı ya eğitimde ya da testte yer alır. Bu, model değerlendirmesinin gerçekçi olması için zorunludur; aksi halde model hastayı 'ezberleyerek' yapay olarak yüksek skor üretir. Sonuç: eğitim 770 örnek (55 hasta), test 196 örnek (14 hasta).

4. Ön İşleme

Tüm ön işleme adımları yalnızca eğitim verisinde **fit** edilmiş, test verisine yalnızca **transform** uygulanmıştır:

- Eksik veri / sonsuz değer: inf değerleri NaN'a çevrilip median imputation ile dolduruldu.
- Düşük varyans filtresi: bilgi taşımayan sabit/yarı-sabit özellikler kaldırıldı.
- Korelasyon eleme: Pearson korelasyonu > 0.95 olan yüksek derecede ilişkili özelliklerden biri elendi.
- Ölçekleme: aykırı değerlere dayanıklı RobustScaler uygulandı.

Bu adımlar sonucunda özellik sayısı 746'dan 234'a inmiştir.

5. Özellik Seçimi (MRMR)

MRMR (Minimum Redundancy Maximum Relevance) yöntemi ile 30 özellik seçilmiştir. İlgililik (relevance) ölçütü olarak hedef ile **Mutual Information**, fazlalık (redundancy) ölçütü olarak seçilmiş özelliklerle **Pearson korelasyonu** kullanılmıştır. Her adımda skoru (ilgililik – ortalama fazlalık) en yüksek özellik eklenir. Özellik seçimi, veri sızıntısını önlemek amacıyla çapraz doğrulamanın içinde, her fold'un kendi eğitim kısmından yapılmıştır.

Seçilen ilk 10 özellik: Feature_0224, Feature_0688, Feature_0570, Feature_0409, Feature_0005, Feature_0028, Feature_0166, Feature_0022, Feature_0408, Feature_0204.

6. Modelleme

Altı taban model eğitilmiştir: Lojistik Regresyon (LR), RBF çekirdekli Destek Vektör Makinesi (SVM), Random Forest (RF), Extra Trees (ET), Gradient Boosting (GB) ve K-En Yakın Komşu (KNN). Her model için olasılık çıktıları **sigmoid (Platt) kalibrasyonu** ile düzeltilmiştir. Ardından kalibre edilmiş RF, ET ve GB modelleri **soft-voting ensemble** ile birleştirilmiştir.

7. Hiperparametre Optimizasyonu

Hiperparametreler **Optuna** ile optimize edilmiştir: **TPE sampler**, model başına **50 deneme**, amaç fonksiyonu **Macro-F1**. İç çapraz doğrulama için **StratifiedGroupKFold (3 katman)** kullanılmış; böylece aynı hasta aynı fold içinde tutularak hem sınıf dengesi hem de hasta bütünlüğü korunmuştur. Özellik seçimi hiperparametreden bağımsız olduğundan fold başına bir kez hesaplanıp önbelleğe alınmış, bu da hesaplama maliyetini önemli ölçüde düşürmüştür.

Model	Seçilen en iyi hiperparametreler
LR	$C=0.007335487295279463$, class_weight=balanced
SVM	$C=1.2915629316911452$, gamma=auto, class_weight=balanced
RF	n_estimators=150, max_depth=12, min_samples_leaf=1, max_features=sqrt, class_weight=balanced
ET	n_estimators=150, max_depth=15, min_samples_leaf=2, max_features=sqrt, class_weight=balanced
GB	n_estimators=50, learning_rate=0.010241977302648288, max_depth=3, subsample=0.99577298776912

KNN	n_neighbors=19, weights=distance, p=1
-----	---------------------------------------

Tablo 2. Optuna ile bulunan en iyi hiperparametreler.

8. Sonular

8.1 Test Seti Performansı

Model	Macro-F1	ROC-AUC	PR-AUC	Accuracy	Recall	Brier
LR	0.659	0.698	0.433	0.872	0.286	0.115
SVM	0.709	0.657	0.501	0.898	0.321	0.098
RF	0.668	0.667	0.485	0.857	0.357	0.107
ET	0.686	0.709	0.515	0.872	0.357	0.103
GB	0.714	0.621	0.462	0.893	0.357	0.107
KNN	0.709	0.744	0.531	0.898	0.321	0.091
Ensemble	0.694	0.678	0.498	0.888	0.321	0.103

Tablo 3. Modellerin test seti metrikleri (en yksek Macro-F1 yeřil ile iřaretli).

Test seti macro-F1 aısından en iyi model **GB** (0.714) olmuřtur. Tm modeller yksek doęruluk ($\approx 88\%$) elde etmekle birlikte, papildem sınıfı iin recall deęerleri dřktr (≈ 0.32). Bunun nedeni, test setindeki belirgin sınıf dengesizlięi (168 Normal / 28 Papildem) ve yalnızca 14 hastadan oluřan grece kk test havuzudur.

8.2 apraz Doęrulama Performansı

Model	LR	SVM	RF	ET	GB	KNN
CV Macro-F1	0.895	0.922	0.905	0.907	0.918	0.897


Tablo 4. Eęitim ii apraz doęrulama Macro-F1 skorları (Optuna en iyi).

Eęitim ii CV skorları (≈ 0.89 – 0.92) test skorlarından yksektir. Bu fark, kk ve hasta-bazlı test havuzunun yarattıęı doęal varyansı ve gereki genelleme performansını yansıtır.


8.3 İstatistiksel Karřılařtırma

Modellerin fold bazlı Macro-F1 skorları zerinde **Friedman testi** uygulanmıřtır: $\chi^2 = 2.025$, $p = 0.917$. $p > 0.05$ olduęundan, modeller arasında istatistiksel olarak anlamlı bir fark saptanmamıřtır. En iyi modele (referans: SVM) karřı yapılan **Wilcoxon signed-rank** testleri ve **Bonferroni dzeltmesi** sonrasında da tm karřılařtırmalarda $p \approx 1.0$ bulunmuř, yani modeller bu veri/blme zerinde birbirinden ayırt edilememiřtir.


8.4 Grafikler



Şekil 1. Test seti ROC eğrileri ve AUC değerleri.




Şekil 2. Test seti Precision-Recall eğrileri.




Şekil 3. Ensemble modeli için karışıklık matrisi (test).



Şekil 4. Modellerin Macro-F1, ROC-AUC ve PR-AUC karşılaştırması.



Şekil 5. Random Forest'a göre en önemli 15 radyomik özellik.



Şekil 6. Ensemble için kalibrasyon eğrisi (sigmoid kalibrasyon öncesi/sonrası).

9. Tartışma

Elde edilen sonuçlar birkaç açıdan dikkat çekicidir. Birincisi, çapraz doğrulama ile test performansı arasındaki fark, hasta seviyesinde bölmenin önemini somut biçimde göstermektedir; eğer bölme görüntü seviyesinde yapılsaydı skorlar yapay olarak çok daha yüksek çıkacaktı. İkincisi, yüksek doğruluğa rağmen düşük recall, dengesiz veri setlerinde tek başına doğruluğun yanıltıcı olduğunu ve Macro-F1 ile PR-AUC gibi ölçütlerin daha bilgilendirici olduğunu vurgular. Üçüncüsü, ensemble modeli tekli modellere kıyasla belirgin bir üstünlük sağlamamış; istatistiksel testler de farkın anlamsız olduğunu doğrulamıştır. Bu, MRMR sonrası özellik uzayının zaten oldukça ayırıştırıcı olmasıyla açıklanabilir.

Çalışmanın temel güçlü yanı, veri sızıntısını önleyen titiz metodolojidir: ön işleme yalnızca eğitimde fit edilmiş, özellik seçimi CV içinde yapılmış ve hasta bütünlüğü korunmuştur. Başlıca kısıt ise hasta sayısının azlığıdır (69 hasta); bu, özellikle test tahminlerinde yüksek varyansa yol açmaktadır.

10. Sonuç

Bu çalışmada, radyomik özelliklerden papilödem sınıflandırması için veri sızıntısız, uçtan uca bir makine öğrenmesi pipeline'ı başarıyla geliştirilmiştir. Hasta-bazlı bölme, MRMR özellik seçimi, Optuna optimizasyonu, kalibrasyon ve ensemble öğrenme entegre edilmiştir. En iyi test performansını GB modeli verirken, modeller arasındaki farklar istatistiksel olarak anlamsız bulunmuştur. Gelecek çalışmalarda daha fazla hasta verisi, nested cross-validation ve SHAP/LIME tabanlı açıklanabilirlik analizleri ile sonuçların güçlendirilmesi önerilir.

Ek: Ödevde İstenen Soruların Cevapları

- Hangi model en iyi performansı verdi? Test Macro-F1'e göre GB (0.714); eğitim içi CV Macro-F1'e göre SVM. Farklar istatistiksel olarak anlamsızdır.
- Ensemble model tekli modellerden daha iyi mi? Hayır; soft-voting ensemble (Macro-F1=0.694) tekli en iyi modelle benzer düzeydedir ve Wilcoxon testinde anlamlı fark yoktur.
- MRMR özellik seçimi performansı artırdı mı? MRMR, özellik sayısını 746→234→30'a indirerek modelleri sadeleştirdi, hesaplamayı hızlandırdı ve aşırı öğrenme riskini azalttı; performansı korurken yorumlanabilirliği artırdı.
- Kalibrasyon model güvenilirliğini artırdı mı? Sigmoid kalibrasyon, olasılık çıktılarını daha güvenilir hale getirmiş ve Brier skorlarını iyileştirmiştir (kalibrasyon eğrisi, Şekil 6).
- ROC-AUC ile PR-AUC arasındaki ilişki nasıl? Sınıf dengesizliği ($\approx 17\%$ pozitif) nedeniyle PR-AUC, ROC-AUC'tan sistematik olarak daha düşüktür ve azınlık (papilödem) sınıfındaki gerçek performansı daha dürüst yansıtır.
- Veri boyutunun model performansına etkisi nedir? Hasta sayısının azlığı (test=14 hasta) tahmin varyansını yükseltir; CV ile test arasındaki fark bu etkinin doğrudan göstergesidir. Daha çok hasta, daha kararlı sonuçlar sağlayacaktır.
- En önemli ilk 10 radyomik özellik hangileridir? Random Forest önem sıralamasına göre: Feature_0224, Feature_0409, Feature_0408, Feature_0500,

Feature_0072, Feature_0034, Feature_0478, Feature_0086, Feature_0008, Feature_0067.

Kaynakça

- Pedregosa et al. (2011). Scikit-learn: Machine Learning in Python. JMLR, 12, 2825–2830.
- Akiba et al. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. KDD.
- Peng, Long & Ding (2005). Feature selection based on mutual information: criteria of max-dependency, max-relevance, and min-redundancy. IEEE TPAMI.
- Niculescu-Mizil & Caruana (2005). Predicting good probabilities with supervised learning. ICML.
- Demšar (2006). Statistical comparisons of classifiers over multiple data sets. JMLR, 7, 1–30.
- van Griethuysen et al. (2017). Computational Radiomics System to Decode the Radiographic Phenotype. Cancer Research.